<u>Liste d'exercices 4 : les entiers et les flottants à simple précision</u> (1 séance)

Notions à considérer pour pouvoir faire les exercices

Priorité des opérateurs :

Priorités	Opérateurs en C	
+++++++	()	
++++++	-, ~, (changement de nature), (casting)	
+++++	*, /, %	
+++++	+, -	
++++	&	
+++	۸	
++	I	
+	=	

Les opérateurs logiques ne peuvent être appliqués que sur des entiers.

Le type de données float :

Types	Tailles	Plage de valeurs acceptée
float	32 bits	$[1.175494351 * 10^{-38},, 3.402823466 * 10^{38}]$

Les instructions de traitement sur les flottants :

Intel a conçu, au cours du temps, 3 générations distinctes d'unités dans ses processeurs pouvant effectuer des traitements sur les flottants :

- 1. **FPU** (Floating-Point Unit) : apparue en 1981, une unité FPU a un fonctionnement basé sur une pile interne et non sur des registres. Par exemple, pour réaliser une addition, les 2 nombres figurant au sommet de la pile interne à la FPU sont dépilés, le calcul est réalisé, puis le résultat est empilé.
- 2. **SSE** (Streaming SIMD (Single Instruction, Multiple Data) Extensions) : apparue avec le Pentium III en 1999, une unité SSE a un fonctionnement classique basé sur des registres.
- 3. AVX (Advanced Vector Extensions) : apparue avec la microarchitecture Sandy Bridge en 2011, une unité AVX est une unité SSE améliorée permettant, notamment, l'usage d'instructions ayant plus de 2 opérandes.

Exemple: voici 3 façons d'écrire en assembleur le code qui correspond à une même instruction d'affectation en langage C:

float f = 52.5, f2 = 2, f3 = 3;

Langage C	Code pour FPU	Code pour SSE	Code pour AVX
f = f + f / f2 + f / f3;	fld f fld f2 fdiv fld f fld f3 fdiv fld f fadd fadd fstp f	movss xmm0, f divss xmm0, f2 movss xmm1, f divss xmm1, f3 movss xmm2, f addss xmm2, xmm0 addss xmm2, xmm1 movss f, xmm2	vmovss xmm0, f vdivss xmm1, xmm0, f2 vdivss xmm2, xmm0, f3 vaddss xmm1, xmm0, xmm1 vaddss xmm2, xmm1, xmm2 vmovss f, xmm2

Dans ce cours, on utilise les instructions SSE pour faire les traitements sur les flottants.

Registres et instructions pour les traitements sur les flottants à simple précision (type float):

- Registres pour le stockage temporaire de flottants: XMM0, XMM1, XMM2, XMM3, XMM4, XMM5, XMM6, XMM7.
- Instructions permettant des opérations sur les flottants à simple précision:
 - \circ *MOVSS opd, ops* effectue opd = ops.
 - \circ ADDSS opd, ops effectue opd = opd + ops.
 - \circ SUBSS opd, ops effectue opd = opd ops.
 - \circ MULSS opd, ops effectue opd = opd * ops.
 - \circ DIVSS opd, ops effectue opd = opd / ops.

L'opérande opd doit être un registre XMM. L'opérande ops peut être un registre XMM ou un emplacement en mémoire du type float.

- Instructions permettant de convertir des nombres d'un type de données vers un autre:
 - CVTTSS2SI opd, ops copie dans opd la partie entière du flottant à simple précision se trouvant dans ops. L'opérande opd doit être un registre général de 32 bits.
 - CVTSI2SS opd, ops convertit l'entier se trouvant dans ops en un flottant à simple précision et copie ce flottant dans opd. L'opérande opd doit être un registre XMM.

Changer le signe d'un flottant :

L'instruction neg n'existe pas avec les flottants. Il faut multiplier le nombre par -1 avec mulss pour changer son signe.

Exemple:

```
float f;
float f1 = 10;
const float fconst = -1;
```

Langage C	Assembleur
,	movss xmm0, f1 mulss xmm0, fconst movss f, xmm0

Les instructions SSE n'acceptent pas une valeur immédiate, ici la valeur -1, comme opérande source. Ceci explique pourquoi la constante fconst contenant la valeur -1 est utilisée dans l'instruction mulss.

<u>Nouvelle contrainte du langage C</u>: quand on a un entier avec un flottant à simple précision dans une opération, l'entier est transformé en un flottant à simple précision et l'opération est réalisée sur des flottants à simple précision.

Exemple:

```
char bVar;
int iVar;
float fVar;
const float f3 = 3;
```

```
Assembleur
                  Langage C
               bVar
                         bVar
                                   fVar + f3;
                                                   movsx
                                                             eax, bVar
                                                                                 // (1) et (4)
                                                   cvtsi2ss xmm0, eax
                                                                                 // (2)
            extension
                      extension
(9)
                                                   mulss
                                                             xmm0, fVar
                                                                                 // (3)
                        signée (1)
           (4)signée
                                                             ebx, iVar
                                                   mov
                                                   sub
                                                             ebx, eax
                                                                                 // (5)
                    conversion vers
                       float(2)
                                                   cvtsi2ss xmm1, ebx
                                                                                 // (6)
                                                   addss
                                                             xmm1, xmm0
                                                                                 // (7)
  conversion vers float(6)
                                 (3)
                                                   addss
                                                             xmm1, f3
                                                                                 // (8)
                                                   movss
                                                             fVar, xmm1
                                                                                 // (9)
                         (7)
                                     (8)
```

Dès la multiplication entre bVar et fVar, le type float s'impose et tout les traitements qui suivent sont réalisés sur des flottants à simple précision.

<u>Les castings explicites</u>:

• Casting d'entier vers flottant à simple précision:

Exemple:

```
char bVar;
int iVar;
float fVar;
```

Langage C	Assembleur		
iVar = (float)bVar + fVar; (5) extension signée (1) conversion vers float(2) conversion vers int (4)	movsx eax, bVar // (1) cvtsi2ss xmm0, eax // (2) addss xmm0, fVar // (3) cvttss2si ebx, xmm0 // (4) mov iVar, ebx // (5)		

Tout d'abord, la valeur de bVar est étendue à 32 bits. Ensuite, l'application du casting (float) entraîne la conversion de la valeur du type int vers le type float. L'addition est alors réalisée sur 2 flottants à simple précision. Enfin, la somme est convertie vers le type int et est copiée dans iVar.

• Casting de flottant à simple précision vers entier:

Exemple:

```
int iVar;
float fVar;
```

Langage C	Assembleur
iVar = (int)fVar + 3;	cvttss2si eax, fVar add eax, 3 mov iVar, eax

Exercices

Écrivez la séquence d'instructions en assembleur qui correspond à chaque instruction d'affectation en langage C suivante (en commentaire en vert figure la valeur à obtenir au final) :

```
char
      b = 40;
int
      i = 20;
      j = -125;
int
float f = 2.7;
const float f281 = 2.81, f35 = 3.5;
  • b = f;
                                          // b = 2
  • f = (int)f281 + i;
                                          // f = 22.0
  • i = j + \sim (int)f;
                                          // i = -128
  • b = j / 2 + -f + f35 / 2;
                                         // b = -62
  • j = \sim (j \land 0xfff) + -(int)f + f35; // j = 3972
  • i = (float)i * j;
                                         // i = -2500
  • i = i * 2 + f - 5 * b;
                                          // i = -157
  f = (f * 100) / (b - 20 | 0xf0);
                                         // f = 1.10655737
  • f = ((int)f * 100) / (~b - 20); // f = -3.00000000
  • f = b * (i \& 0x0f | 0x1f00) - f; // f = 317597.313
  • f = (-i + f281 - -b * f + f35) / 2; // f = 47.1549988
  • f = b / 2 + i / f + (b - 3); // f = 64.4074097
  • j = f + (0xf2 \mid i) / (b - 32) / -f; // j = -8
```